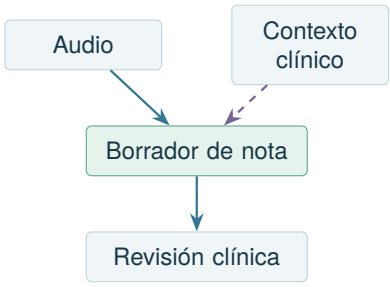
Construir un escriba digital médico

De la consulta a una nota clínica



Borrador técnico · 30 minutos
Tareas, evaluación, modelos y ejecución local

Objetivo y alcance

Documentar el encuentro y facilitar la revisión del profesional.



¿Cómo producir una nota correcta y reducir el trabajo de cerrarla?

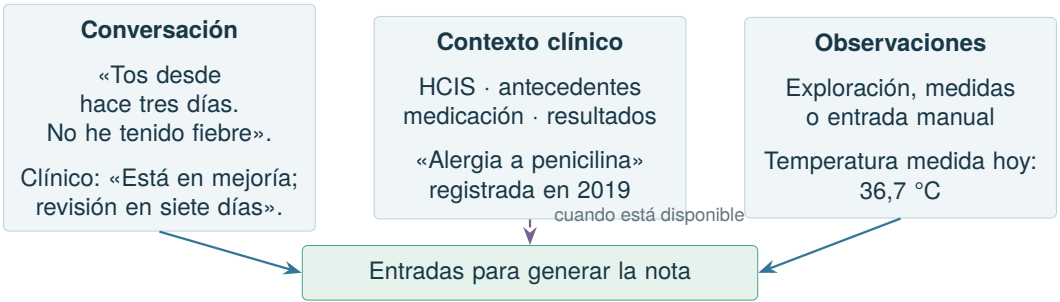
1. Consulta y nota
2. Evaluación y datos
3. Audio y hablantes
4. Diálogo, contexto y nota
5. Adaptación y despliegue
6. Plan de trabajo

Los escribas humanos documentan bajo supervisión clínica. Algunos productos amplían esta función a informes, codificación o ayuda a decisiones; aquí estudiamos la nota.

Fuentes: Ash et al., Safe use of the EHR; Coiera et al., Taking note; Tandem: funciones declaradas del producto.

Información del encuentro

Ejemplo ficticio que seguiremos hasta la nota.



Conservar quién aporta cada dato, cuándo y de qué fuente procede.

Fuentes: The anatomy of clinical documentation (2021); MedAlign (2023). Ejemplo propio.

La nota SOAP

Una forma habitual de estructurar la nota; las plantillas cambian entre servicios.

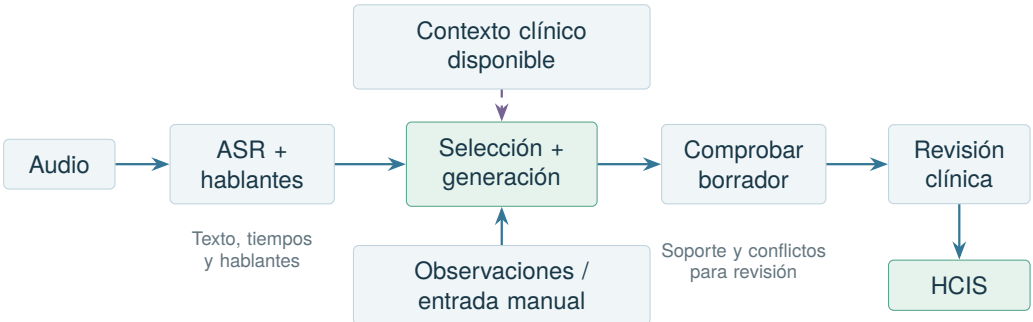
S	**Subjetivo**	Tos de tres días; niega fiebre.	Relato del paciente
O	**Objetivo**	Temperatura: 36,7 °C.	Medición de hoy
A	**Valoración**	En mejoría, según valoración clínica.	Juicio expresado por el clínico
P	**Plan**	Revisión en siete días, indicada por el clínico.	Decisión expresada en consulta

Contexto adicional: alergia registrada en 2019, pendiente de confirmar. Puede aparecer en una sección específica de antecedentes/alergias.

Fuentes: SOAP Notes, StatPearls; The anatomy of clinical documentation. Ejemplo ficticio; A y P documentan al clínico.

Pipeline del escriba

Entradas y salidas que podamos inspeccionar.

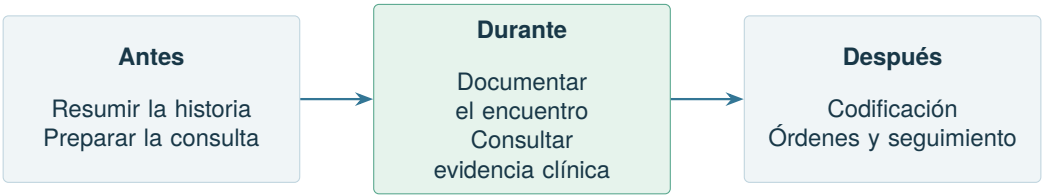


La selección de hechos puede ocurrir dentro del generador o quedar explícita. Comprobar el borrador aporta señales de revisión; su fiabilidad también se evalúa.

Fuentes: Diseño de trabajo, no implementación completa. Evaluación clínica por etapas; Singh et al.; VeriFact. HCIS: sistema de información clínica.

Del escriba al flujo clínico

La expansión de producto: «medical OS» conectado a la historia clínica.



Nuestro alcance: generar y revisar la nota.
Apoyo a decisiones y automatización requieren evaluación propia.

Fuentes: Dirección comercial, no evidencia de eficacia: Tandem: roadmap 2026; Tandem: apoyo con fuentes; Abridge: flujo clínico; codificación. Disponibilidad variable por función y mercado.

Evaluación

El éxito se mide en la nota y en el trabajo necesario para cerrarla.

Audio y hablantes	¿Se reconocieron las palabras y quién las dijo? WER, errores clínicos y atribución.
Contenido de la nota	¿Qué falta, qué sobra y qué se contradice? Hechos, negación, sujeto, fecha y soporte.
Uso clínico	¿Cuánto esfuerzo exige revisar y corregir? Tiempo, ediciones e incidencias del flujo.

Necesitamos referencias anotadas para medir errores y revisión clínica para valorar su importancia.

Fuentes: Moramarco et al., evaluación y post-edición; Marco clínico de evaluación (2025).

Datos de evaluación

Primero referencias estándar; después datos que se acerquen al uso previsto.

1 · Referencias generales

LibriSpeech
960 h de entrenamiento ASR; inglés leído.

AMI
Unas 100 h de reuniones; audio y hablantes.

FLEURS
102 idiomas, unas 12 h/idioma; incluye español.

2 · Consulta clínica en inglés

PriMock57
57 consultas simuladas; 8 h 38 min; audio, turnos y notas.

ACI-Bench
207 encuentros simulados; transcripciones y notas; sin audio público.

MTS-Dialog
1.701 pares breves diálogo–sección.

3 · Aproximación al español clínico

TEME-v1
90 diálogos, 2.330 turnos, 3,96 h de audio TTS; dos voces.

Útil para explorar ASR; sin tiempos de referencia para evaluar DER directamente.

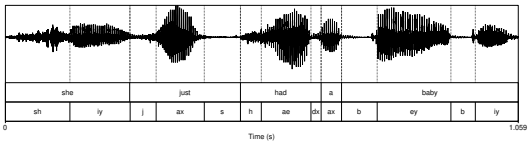
Conjunto local propuesto
Consultas y notas revisadas del escenario de uso.

Fuentes: LibriSpeech; AMI; FLEURS; PriMock57; ACI; MTS; TEME. Horas TEME: suma local de los 90 MP3.

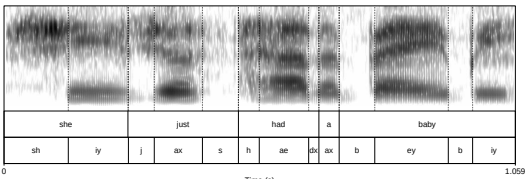
Señal y representación acústica

«She just had a baby»: la misma frase en onda y espectrograma.

Onda y alineamiento



Espectrograma



Captura
Canales, muestreo, ruido y compresión.

Ventanas
Analizar cómo cambia el espectro con el tiempo.

Entrada del modelo
Log-Mel, o representación aprendida de la onda.

Fuentes: Jurafsky y Martin, cap. 15, figs. 15.15 y 15.22, borrador 19/08/2026. Recortes del libro; habla de Switchboard en inglés, no consulta clínica. Whisper: entrada log-Mel.

CTC, transducer y atención

Tres familias que siguen en uso.

CTC · 2006

Encoder acústico
→ etiqueta por frame

↓

Colapsar repeticiones
y símbolos blank

Ejemplo
Parakeet-CTC

RNN-T · 2012

Estado de audio
+ predictor del texto

↓

Emitir token
o avanzar en el audio

Derivado actual
Parakeet-TDT v3

Atención · 2015

Audio codificado
+ texto anterior

↓

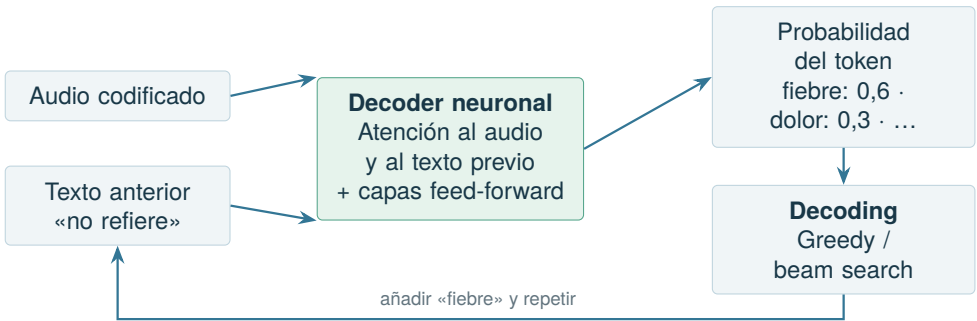
Decoder con atención
→ siguiente token

Ejemplos
Whisper · Canary

Fuentes: CTC (2006); RNN-T (2012); atención para ASR (2015). Ejemplos actuales: Parakeet CTC; Parakeet TDT; Canary. Fechas de trabajos de referencia; las familias coexisten.

Qué hace el decoder

Ejemplo: el decoder Transformer de Whisper.



La red calcula probabilidades; el algoritmo de decoding elige la secuencia. CTC usa colapso de etiquetas; RNN-T combina predictor del texto y estado acústico.

Fuentes: Jurafsky y Martin, cap. 16; Whisper; Survey ASR. Probabilidades y tokens ilustrativos.

WER y errores clínicos

WER = Word Error Rate. Referencia: «el paciente no refiere fiebre desde ayer» · 7 palabras.

A · Sustitución

este paciente no refiere fiebre desde ayer

B · Omisión de una negación

el paciente **[—]** refiere fiebre desde ayer

$$\mathrm{WER} = \frac{S+D+I}{N}$$

Ambos: $1/7 = 0{,}143$
14,3 %

S: sustituciones · D: eliminaciones · I: inserciones · N: palabras de referencia.

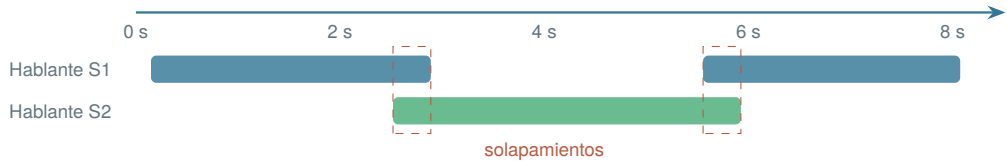
Qué hacemos: anotar errores clínicos; probar vocabulario/hotwords para términos y adaptar ASR si persisten. Volver a medir negación, dosis y omisiones en test.

Fuentes: Definición y cálculo: JiWER; evaluación médica: Medical ASR benchmark (2024); TEME. Ejemplo propio.

Diarización: tiempo, hablante y rol

S1/S2 identifican voces dentro del audio. El rol clínico es otra etiqueta.

1. Quién habla y cuándo



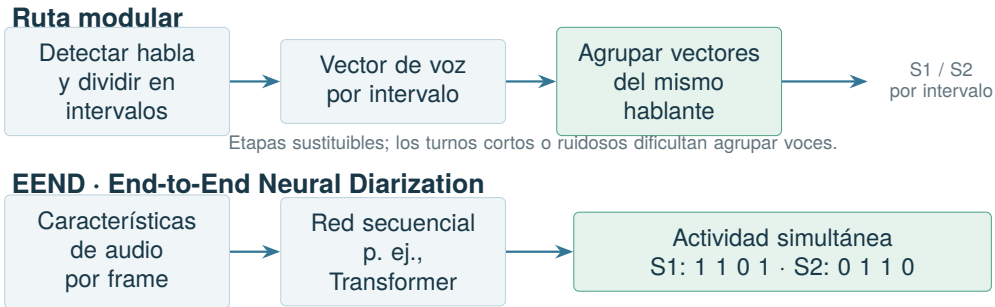
2. Qué dice
S1: «¿Ha tenido fiebre?»

3. Rol, tras comprobarlo
S1: clínico · S2: paciente

Fuentes: DIHARD III; dscore. Línea temporal ilustrativa; el rol es una etiqueta adicional.

Modelos de diarización

Ambas rutas reciben audio y producen intervalos de actividad por hablante.

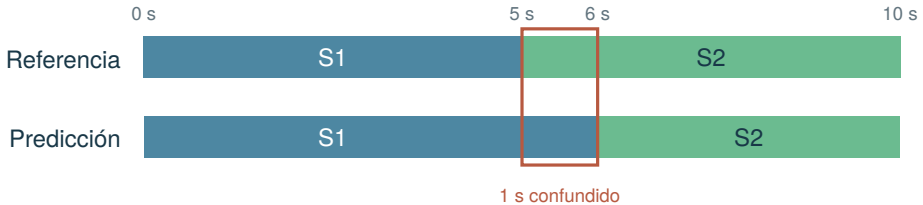


EEND aprende actividad conjunta y solapamientos. El manejo de sesiones largas y del número de hablantes depende de la variante.

Fuentes: EEND con self-attention; pyannote; powerset. Esquemas simplificados.

DER: cuánto tiempo se atribuyó mal

Diarization Error Rate · ejemplo sin solapamientos ni tolerancia en los límites.

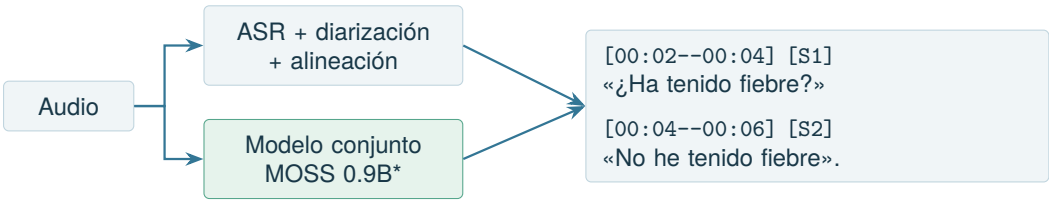


$$\mathrm{DER} = \frac{\text{habla omitida + falsa alarma + confusión}}{\text{tiempo de habla de referencia}} = \frac{1}{10} = 10\,\%$$

Fuentes: dscore; MeetEval. Etiquetas emparejadas con la referencia; ejemplo propio. Collar = margen temporal que el protocolo puede excluir al puntuar.

Transcripción con hablantes

La transcripción diarizada puede ser modular o conjunta.



Una salida común: inicio · fin · hablante · texto

* MOSS-Transcribe-Diarize. Salida ilustrativa; las etiquetas no establecen por sí solas los roles.

Fuentes: MOSS-Transcribe-Diarize (2026); MeetEval. Salida ilustrativa.

Palabras correctas, hablante equivocado

cpWER: concatenated minimum-permutation Word Error Rate.

Referencia	Predicción	
S1: «tengo tos» S2: «desde cuándo»	S1: «tengo tos **desde**» S2: «cuándo»	WER global **0 %**

Por hablante: una inserción en S1 + una eliminación en S2

$$\mathrm{cpWER} \quad = \quad 2/4 \quad = \quad \mathbf{50\,\%}$$

tcpWER: Time-Constrained minimum-Permutation WER

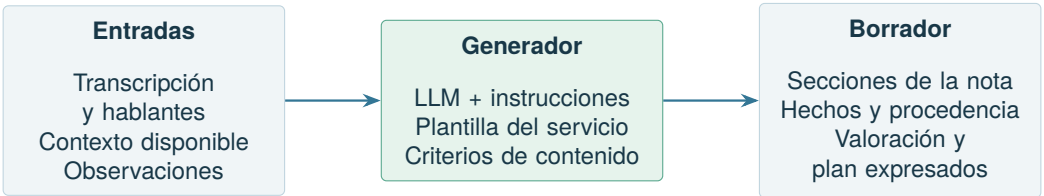
Añade tiempo: las palabras solo se emparejan si sus intervalos son compatibles.

Se busca la mejor permutación de S1/S2: cambiar sus nombres no es un error. En tcpWER hay que fijar la tolerancia temporal.

Fuentes: MeetEval: definiciones y cálculo. Ejemplo propio, sin puntuación. «desde» cambia de hablante; el orden global de palabras se conserva.

Generación de notas

Primero definir qué documentar y cómo debe verse la salida.



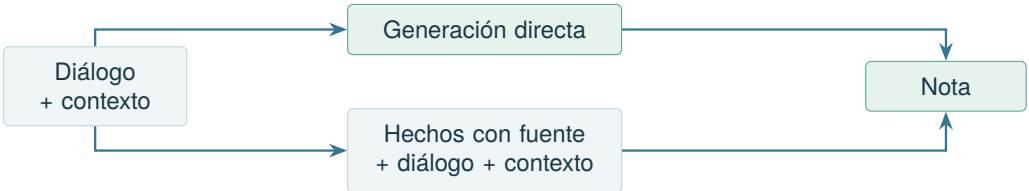
El equipo clínico define contenido, estilo y errores relevantes; esas decisiones se convierten en instrucciones y criterios de evaluación.

Comparar plantillas y prompts sobre los mismos encuentros antes de decidir si hace falta adaptar pesos.

Fuentes: ACI-Bench; Moramarco et al.. Baseline propuesto para el proyecto.

Selección de hechos

La relevancia puede decidirse al redactar o representarse antes de la nota.



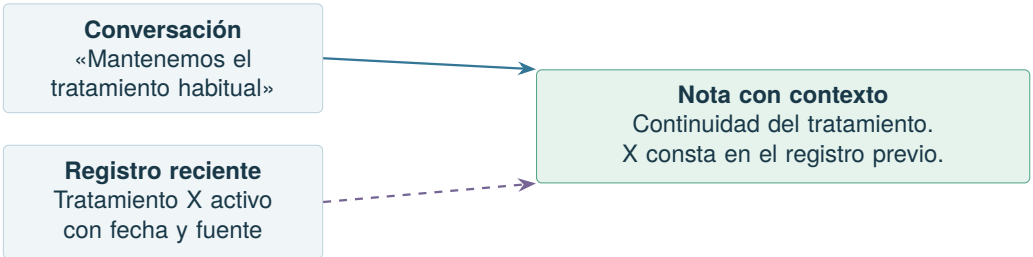
«Mi madre toma X» → **sujeto: madre**, no paciente
Hecho · sujeto · negación · momento · fragmento de soporte

ASCRIBE: hechos + soporte + relevancia. KOSMOS: entidades, atributos y relaciones. Son estrategias para comparar; la extracción puede introducir omisiones.

Fuentes: ASCRIBE (2026, preprint; tailandés); KOSMOS (2026); antecedente: Chain-of-Clinical-Facts, Nuance (2023). Sin validación local en español.

Qué aporta la historia clínica

Completar información que la conversación presupone o no repite.



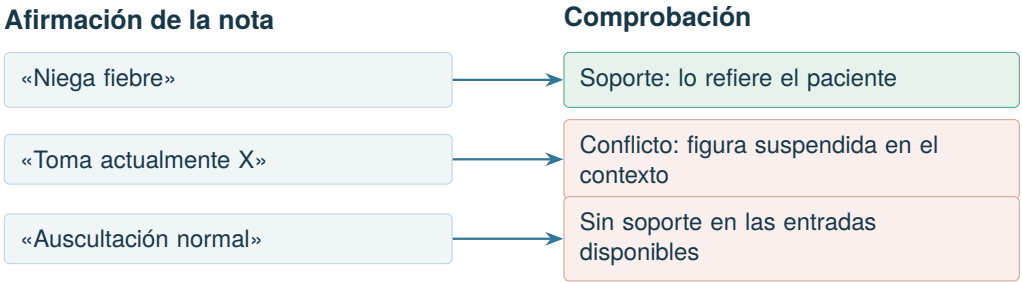
Paciente y corte temporal → seleccionar registros → contexto con procedencia

¿Mejora la calidad? Un preprint con 354 encuentros encuentra mayor completitud. Evaluación principalmente automática y autores del proveedor; falta validación local. Más contexto también puede introducir datos obsoletos.

Fuentes: Ejemplo propio, no recomendación clínica. Zuckerman et al. (2025), ambient-only vs. historia; RAG; procedencia FHIR.

Qué comprueba el verificador

¿Qué respalda cada afirmación y qué información relevante falta?

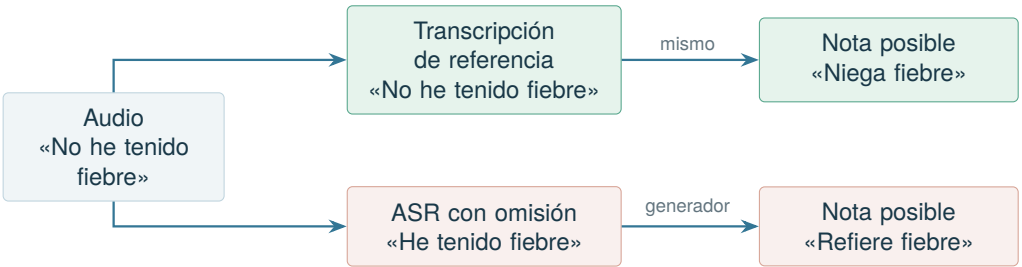


En uso: contrasta nota con conversación e historia. **Para evaluarlo:** médicos etiquetan ejemplos y medimos cuántos avisos y errores detecta correctamente.

Fuentes: VeriFact; FactEHR; Evaluación mediante checklists (2025). Ejemplos ficticios.

Propagación de errores

Propagación ilustrativa: una transcripción errónea puede producir una nota muy fluida.



Si generador y verificador leen el mismo ASR erróneo, pueden compartir el fallo. Conservar el vínculo con el audio.

Fuentes: Latif et al., Robust SOAP (2026); Marco de evaluación clínica (2025). Esquema causal propuesto; sin resultados experimentales.

Robust SOAP: probar errores controlados

Texto original / texto con un error → mismo generador → comparar hechos de las notas.

Table 1: Taxonomy of transcription errors for robustness analysis.

ID	Error Type	Description	Example
(1)	Censor Medical Term	Remove drug names, conditions, allergies	"metformin" → [BLANK]
(2)	Censor Numerical Value	Remove doses, frequencies, durations	"aspirin, seventy five milligrams, once a day" → "aspirin, once a day"
(3)	Censor Diagnosis	Remove diagnostic terms	"You seem to have labyrinthitis" → "You seem to have"
(4)	Symptom Omission	Remove entire symptom mention dialogue	Complete sentence removal
(5)	Negation Flip	Invert yes/no responses	"no fever" → "fever"
(6)	Medical Homophone	Replace with similar-sounding medical term	"Trimethoprim" → "Triamterene"

51 consultas de PriMock tras depuración; 44 errores inducidos. Evalúan sobre texto, sin ejecutar ASR ni evaluar diarización. Nuestra ampliación: español, audio real del pipeline y recursos locales.

Fuentes: Latif et al., CHIL 2026, tabla 1, p. 454: recorte original, © autores. Evaluación: hechos frente a nota de referencia; adiciones contrastadas con el diálogo. Resultados originales: anexo F.

Qué adaptar y con qué datos

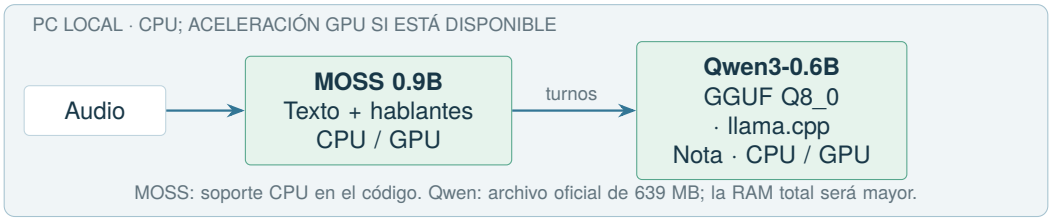
Del error de contenido al coste de ejecutarlo: calidad, tiempo y memoria.

Fallo	Qué probar	Qué necesitamos
Términos o acentos en ASR	Vocabulario / hotwords; fine-tuning si persiste	Audio y texto revisado; test clínico español
Formato u omisiones de la nota	Plantilla, prompt o selección de hechos	Diálogo/contexto y nota; rúbrica clínica
Tiempo o memoria excesivos	Motor, modelo pequeño o cuantización	Mismos casos en el PC objetivo; calidad y recursos

Fuentes: Plan propuesto. MOSS: hotwords; LoRA; ASCRIBE; llama.cpp.

Un escriba en el PC del médico

Configuración candidata: audio y nota procesados en el propio equipo.

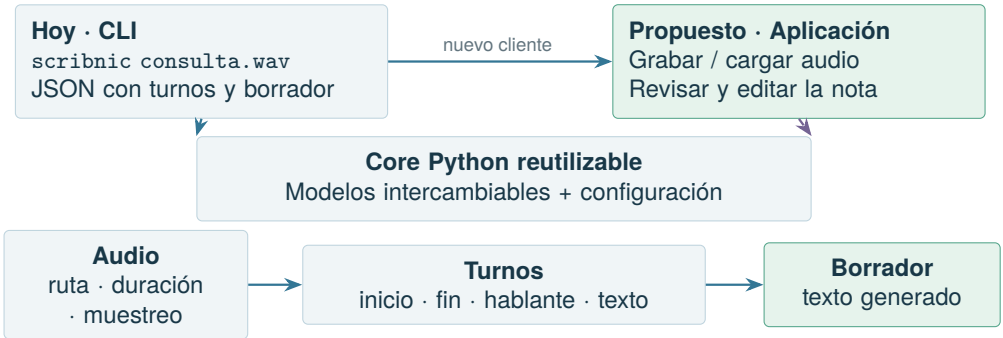


Prueba pendiente: RAM máxima, tiempo por consulta y calidad de la nota en español.

Fuentes: MOSS 0.9B; selección CPU/GPU; Qwen oficial: tamaño en disco; llama.cpp. Sin benchmark propio ni calidad clínica demostrada.

Scribnic: de la CLI a una aplicación

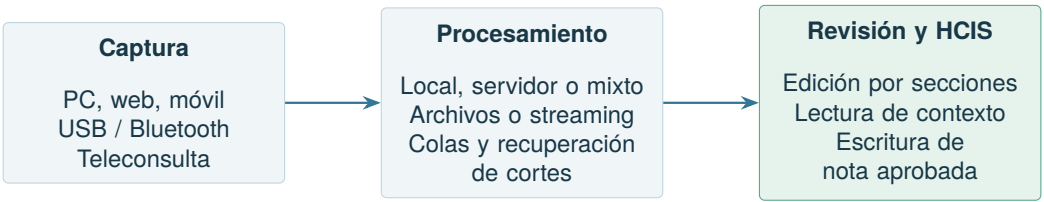
El frontend usa la misma pipeline y los mismos tipos de datos.



Fuentes: Código local: `scribnic/core.py`, `models.py`, `factory.py` y CLI. El núcleo y los tipos existen; el cliente de revisión y la evaluación clínica están pendientes.

Captura e integración

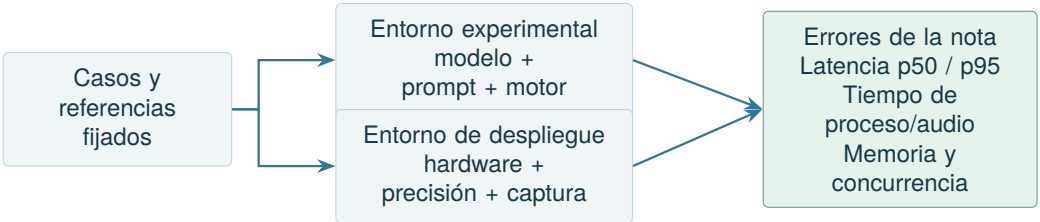
La plataforma determina cómo llega la información y cómo se revisa.



Fuentes: Captura web; WebRTC; FHIR DocumentReference; Tandem: edición por voz y documentos. Opciones de diseño, no conectores implementados.

Evaluación del sistema desplegado

Comprobar calidad y funcionamiento en la configuración de uso.



Después de cada cambio, repetir la evaluación. En piloto: fallos, ediciones y muestra revisada de calidad.

Fuentes: Protocolo propuesto. faster-whisper; whisper.cpp. Sin benchmark de rendimiento local todavía.

Datos del primer experimento

Adaptar Robust SOAP a nuestros datos y ejecución local; añadir audio, hablantes y contexto.

1 · Componentes

TEME: ASR español TTS
PriMock57: audio, turnos y notas en inglés

Referencias públicas

2 · Contexto y nota

10 casos con contexto
5 consultas PriMock adaptadas al español

Referencias revisadas

3 · Protocolo clínico

Hechos y fuentes esperados
Errores, omisiones y edición
Acuerdo entre revisores

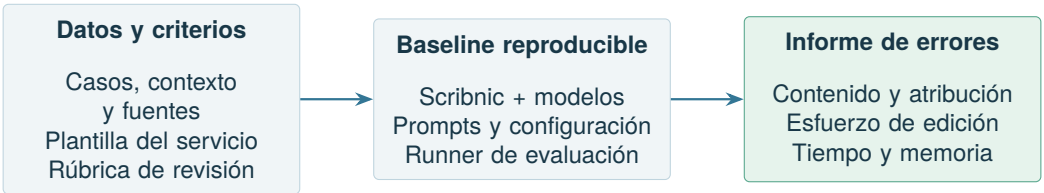
Test separado del ajuste

Números propuestos para una prueba de viabilidad. Datos sintéticos y traducciones no sustituyen una evaluación posterior con consultas reales.

Fuentes: Plan del proyecto; Robust SOAP como referencia metodológica. TEME-v1; PriMock57; Marco clínico de evaluación. Ampliaciones: bag-of-ideas.md y anexo D.

Propuesta de trabajo

Construir un baseline local y averiguar dónde necesita mejorar.



La evaluación decidirá qué adaptar y qué merece pasar a un piloto supervisado.

El hospital aporta acceso a criterios clínicos y revisores. El objetivo abierto y local necesita primero evidencia de calidad y viabilidad.

A · Datasets: referencias adicionales y volumen

Una selección para profundizar; horas, encuentros y pares miden cosas distintas.

Recurso	Volumen	Uso y límite principal
Common Voice 17 · ES	2.220 h totales; 562 h validadas	ASR general en español; lectura, no consulta.
DIHARD III	Dev: 34,15 h / 254 grabaciones; eval: 33,01 h / 259	Diarización en dominios diversos; fijar protocolo.
VoxConverse	Más de 50 h, según página del corpus	Vídeo multihablante; distinto del entorno clínico.
MedAlign	983 instrucciones; 303 respuestas de referencia; 276 EHR	Uso de historia clínica; no corpus audio→SOAP.
MedNLI	14.049 pares: 11.232 / 1.395 / 1.422	Inferencia clínica textual; dominio hospitalario.
MIMIC-IV-Note 2.2	331.794 altas; 2.321.355 informes radiológicos	Documentación clínica; sin audio emparejado.
FactEHR	2.168 notas; 987.266 pares de inferencia; 1.036 ejemplos humanos	Verificación: distinguir datos generados de validación humana.

Fuentes: Common Voice ES; DIHARD III; VoxConverse; MedAlign; MedNLI; MIMIC-IV-Note; FactEHR. Detalle de versiones y acceso: README.md.

B · Tarea, métrica y loss: mapa de consulta

Tarea	Evaluación	Objetivos de entrenamiento habituales
ASR	WER / CER; entidades y errores clínicos	CTC; CE/NLL; transducer. Preentrenamiento autosupervisado según modelo.
Diarización	DER / JER, con collar y solapamiento definidos	BCE + PIT (EEND); CE powerset; pérdidas de embeddings, p. ej. margen angular.
Transcripción diarizada	cpWER / tcpWER; WER y DER complementarios	CE sobre secuencias serializadas o pérdidas separadas en sistemas modulares.
Recuperación	Recall@k / nDCG; paciente, fecha y relevancia	Contrastiva para retrievers densos; CE/ranking en rerankers.
Generación de nota	ROUGE/BERTScore + hechos, omisiones, contradicciones y revisión clínica	CE/NLL; ranking de candidatos (BRIO); ponderación clínica según trabajo.
Verificación	Precision/recall/F1; calibración; errores por tipo	CE para clasificación de inferencia; CE de generación, si se adapta un LLM.
Sistema completo	Calidad de nota + revisión + tiempo + incidencias	Depende de la arquitectura. No existe una única loss estándar audio→nota.

Fuentes: Jurafsky y Martin, cap. 16; EEND; BRIO; DPR; MedNLI. Catálogo ampliado: README.md.

C · Hechos intermedios: tres implementaciones

Representar hechos del encuentro es distinto de recuperar historia externa.

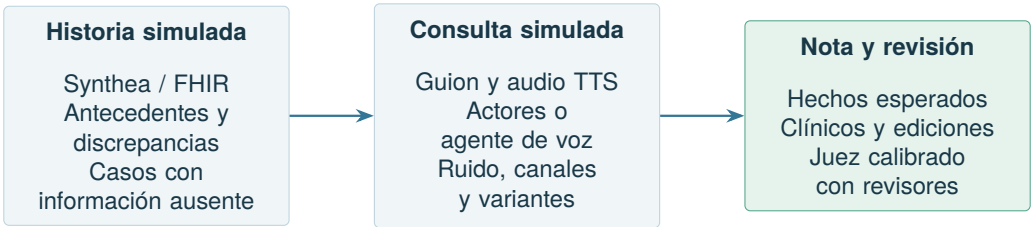
Trabajo	Qué hace	Qué limita la conclusión
Nuance (2023)	Hechos extraídos de notas de referencia como prefijo de entrenamiento; en inferencia, genera hechos y después nota desde la transcripción.	≈900.000 encuentros privados en inglés. No incorpora HCIS por retrieval.
ASCRIBE (2026)	Hechos atómicos + soporte + relevancia antes de SOAP; prompting y adaptación con rewards.	Tailandés; muestra clínica pequeña; jueces LLM y validación limitada con un médico. Preprint.
KOSMOS (2026)	Entidades, atributos y relaciones con procedencia; compara transcripción + nodos/grafo.	Mejoras modestas; extracción sin evaluación independiente; no demuestra menor tiempo de revisión.

Experimento propuesto: directo frente a hechos con fuente + diálogo, manteniendo casos, contexto, plantilla y generador.

Fuentes: Singh et al. §3.1.2; ASCRIBE §3.1 y prompt A.3; KOSMOS §2. Ficha: comprension-clinica.md.

D · Ideas para ampliar los datos

Experimentos posibles después del primer conjunto de viabilidad.



MIRA aporta un entorno EHR/paciente para decisiones clínicas; no un corpus audio→nota. Adaptar PriMock al español y recoger consultas reales son otras vías.

Fuentes: Synthea; MIRA (2026; acceso MIMIC controlado); PriMock57. Propuestas y límites en bag-of-ideas.md.

E · Lecturas para preparar la discusión

Para entender…	Empezaría por…
La consulta y la nota	The anatomy of clinical documentation; Safe use of the EHR. Contenido, fuentes y revisión.
Audio y ASR	Jurafsky, cap. 15 y cap. 16; Whisper. Señal, características y reconocimiento.
Hablantes	EEND; powerset; MeetEval. Actividad, atribución y protocolo.
Selección y contexto	ASCRIBE; KOSMOS; Nuance. Leer método y limitaciones; ficha comprension-clinica.md.
Evaluación de notas	Moramarco et al.; Robust SOAP; VeriFact. Revisión, omisión y soporte.

Guion con hilo, tiempos y transiciones: guion-presentacion.md

Preguntas de defensa y ejercicios: preguntas-defensa.md · Datos y volúmenes: README.md

F · Robust SOAP: resultados publicados

Tabla original: cobertura, omisiones, contradicciones y contenido añadido.

Table 2: Overall model performance on SOAP note generation. Best values are **bolded**, second-best are underlined. Values represent mean ± standard deviation across all consultations.

Model	Coverage ↑	Omission ↓	Contradiction ↓	Addition ↓	Elaboration ↓
GPT-4.1	81.84 ± 0.70	10.38 ± 0.55	7.78 ± 0.16	0.61 ± 0.03	20.85 ± 0.19
GPT-4.1 mini	79.29 ± 1.26	13.60 ± 1.48	7.12 ± 0.22	1.14 ± 0.24	19.93 ± 0.52
GPT-4o	69.14 ± 0.22	23.96 ± 0.02	6.89 ± 0.19	0.39 ± 0.04	18.91 ± 1.20
GPT-5.2	83.93 ± 1.15	9.20 ± 0.23	6.88 ± 0.91	**0.24 ± 0.06**	22.27 ± 0.13
GPT-5	**85.28 ± 0.34**	**8.48 ± 0.23**	**6.24 ± 0.11**	0.41 ± 0.16	22.70 ± 0.39
GPT-5 mini	78.94 ± 0.60	13.18 ± 0.69	7.88 ± 0.09	2.02 ± 0.39	**18.54 ± 2.47**
GPT-5 nano	77.63 ± 1.38	14.82 ± 0.41	7.54 ± 0.97	4.00 ± 0.16	21.98 ± 0.45
o3	83.52 ± 0.11	9.92 ± 1.24	6.56 ± 1.13	3.50 ± 0.82	20.37 ± 0.13

Resultados de los autores en inglés, con jueces LLM. «Elaboration» recoge contenido adicional respaldado por el diálogo: no equivale a alucinación, pese a la flecha descendente del original. No es un ranking de modelos locales.

Fuentes: Latif et al., CHIL 2026, tabla 2, p. 456: recorte sin modificar, © autores. Limitaciones de reproducción y lectura de las métricas: ficha robust-soap.md.