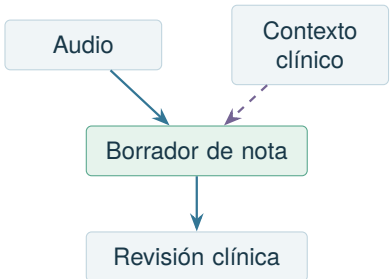
Construir un escriba digital médico

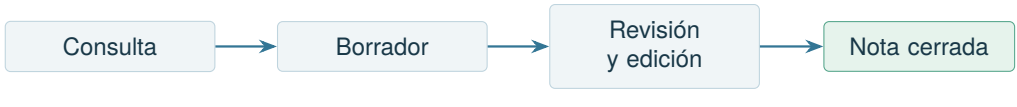
De la consulta a una nota verificable



Borrador técnico · 30 minutos
Tareas, datos, modelos, evaluación y despliegue

El objetivo: cerrar una nota útil con menos esfuerzo

La unidad de éxito es el trabajo clínico completo.



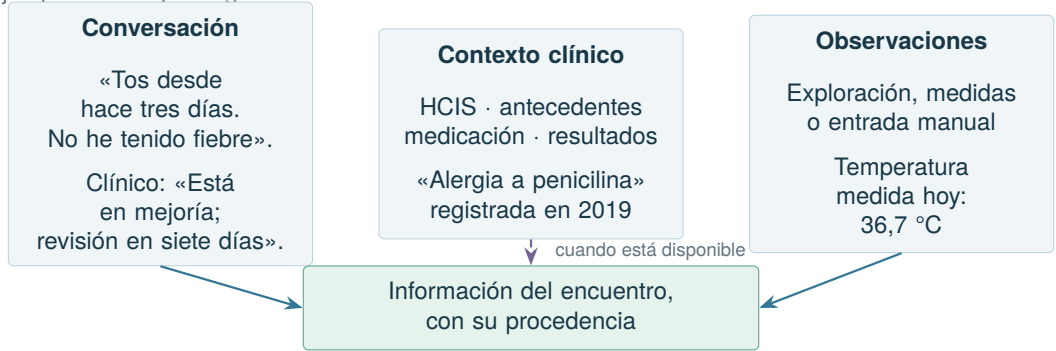
1. Consulta y nota
2. Evaluación y datos
3. Audio y hablantes
4. De contexto a nota
5. Experimento y despliegue
6. Siguientes pasos

Pregunta técnica: ¿qué necesita el sistema para producir una nota correcta y fácil de revisar?

Fuentes: Coiera et al., Taking note (2018); Ash et al., Safe use of the EHR (2021; escribas humanos).

La consulta produce tres fuentes de información

Ejemplo ficticio que seguiremos hasta la nota.



Una nota combina lo dicho, lo observado y el contexto relevante; cada fuente necesita interpretación.

Fuentes: The anatomy of clinical documentation (2021); MedAlign (2023). Ejemplo propio.

SOAP organiza hechos, valoración y decisiones

Una forma habitual de estructurar la nota; las plantillas cambian entre servicios.

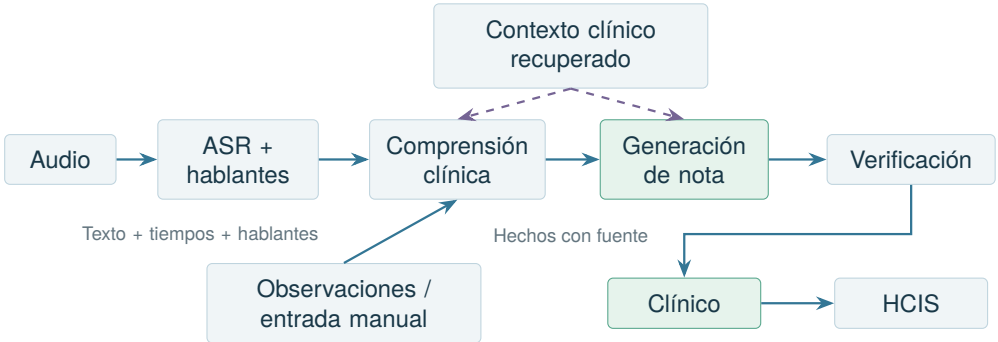
S	**Subjetivo**	Tos de tres días; niega fiebre.	Relato del paciente
O	**Objetivo**	Temperatura: 36,7 °C.	Medición de hoy
A	**Valoración**	En mejoría, según valoración clínica.	Juicio expresado por el clínico
P	**Plan**	Revisión en siete días, indicada por el clínico.	Decisión expresada en consulta

Contexto adicional: alergia registrada en 2019, pendiente de confirmar. Puede aparecer en una sección específica de antecedentes/alergias.

Fuentes: SOAP Notes, StatPearls; The anatomy of clinical documentation. Ejemplo ficticio; A y P documentan al clínico.

Una pipeline con entradas y salidas explícitas

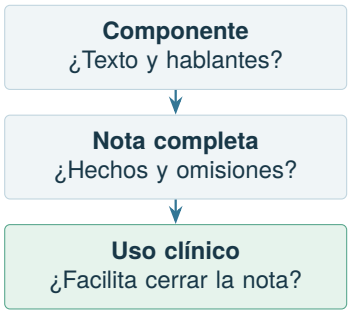
Las cajas representan funciones: un modelo puede resolver varias.



Fuentes: Síntesis propuesta a partir de Taking note; marco de evaluación clínica (2025); MedAlign. HCIS: sistema de información clínica.

Cada nivel responde a una pregunta distinta

Separar diagnóstico del componente, calidad de la nota y utilidad en consulta.



WER / CER · DER / JER · cpWER / tcpWER
El error depende de la normalización y del protocolo.

Omisiones · adiciones sin soporte · contradicciones
Hechos clínicos, negación, atribución y temporalidad.

Edición y revisión · tiempo total · incidencias
Con el flujo y la integración que se usarán.

La **loss** guía el entrenamiento. Las **métricas** y la revisión clínica comprueban qué se consiguió.

Fuentes: JiWER; dscore; MeetEval; Moramarco et al. (2022).

Del benchmark general al caso clínico español

Primero referencias estándar; después datos que se acerquen al uso previsto.

1 · Referencias generales

LibriSpeech
960 h de entrenamiento ASR; inglés leído.

AMI
Unas 100 h de reuniones; audio y hablantes.

FLEURS
102 idiomas, unas 12 h/idioma; incluye español.

2 · Consulta clínica en inglés

PriMock57
57 consultas simuladas; 8 h 38 min; audio, turnos y notas.

ACI-Bench
207 encuentros simulados; transcripciones y notas; sin audio público.

MTS-Dialog
1.701 pares breves diálogo–sección.

3 · Aproximación al español clínico

TEME-v1
90 diálogos, 2.330 turnos, 3,96 h de audio TTS; dos voces.

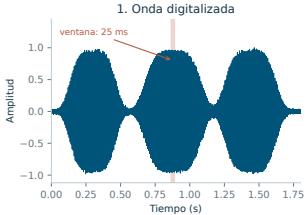
Útil para explorar ASR; sin tiempos de referencia para evaluar DER directamente.

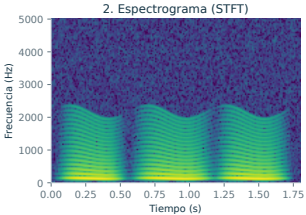
Conjunto local propuesto
Consultas y notas revisadas del escenario de uso.

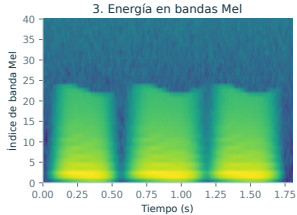
Fuentes: LibriSpeech; AMI; FLEURS; PriMock57; ACI; MTS; TEME. Horas TEME: suma local de los 90 MP3.

Del micrófono a una representación acústica

El modelo recibe una señal muestreada o características derivadas de ella.







Captura
Muestreo, canales, ganancia, ruido y pérdidas.

Ventanas temporales
Ejemplo: 25 ms de ventana; avance de 10 ms.

Representación
Log-Mel, o una representación aprendida desde la onda.

La preparación del audio debe coincidir con lo que espera el modelo.

Fuentes: Jurafsky y Martin, cap. 15; Whisper. Figura propia con señal sintética; no representa voz de un paciente.

ASR: tres formas de aprender audio→texto

Arquitectura, alineamiento y objetivo de entrenamiento son decisiones relacionadas.



Whisper usa encoder–decoder. HuBERT aprende representaciones con predicción enmascarada; necesita adaptación para ASR. Conformer describe un encoder.

Fuentes: CTC; RNN-T; Whisper; HuBERT; Conformer.

El mismo WER puede ocultar errores muy distintos

Referencia: «el paciente no refiere fiebre desde ayer» · 7 palabras.

A · Sustitución

este paciente no refiere fiebre desde ayer

B · Omisión de una negación

el paciente **[—]** refiere fiebre desde ayer

$$\mathrm{WER} = \frac{S+D+I}{N}$$

Ambos: $1/7 = 0{,}143$
14,3 %

Añadir revisión de entidades, negaciones, dosis, fechas y su impacto clínico. El WER sigue siendo útil para diagnosticar ASR.

Fuentes: Definición y cálculo: JiWER; evaluación médica: Medical ASR benchmark (2024); TEME. Ejemplo propio.

Voz, palabras y rol son etiquetas diferentes

Un identificador de hablante no identifica por sí mismo a una persona ni su rol clínico.

1. Quién habla y cuándo



2. Qué dice
S1: «¿Ha tenido fiebre?»

3. Qué rol tiene
S1: clínico · S2: paciente, tras validarlo

Fuentes: DIHARD III; dscore. Línea temporal ilustrativa; el rol es una etiqueta adicional.

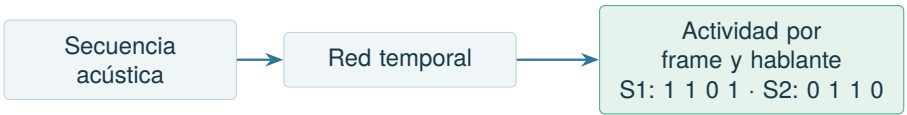
Diarización: agrupar voces o predecir actividad

Dos familias; ruido, turnos cortos y solapamiento ponen a prueba ambas.

Modular



End-to-end neural diarization (EEND)

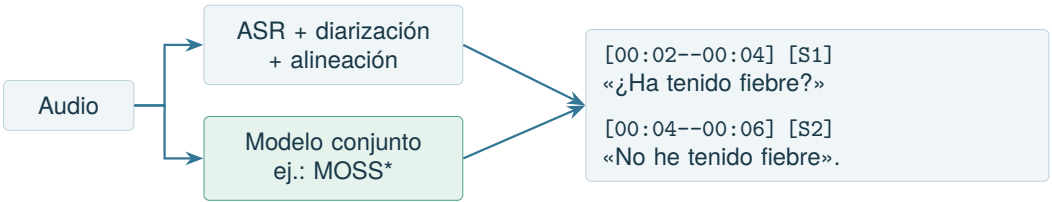


Loss EEND: BCE con asignación de hablantes invariante a permutación (PIT). **Powerset:** CE sobre combinaciones de hablantes activos. **Evaluación:** DER/JER; fijar collar y tratamiento del solapamiento.

Fuentes: Fujita et al., EEND (2019); Plaquet y Bredin, powerset (2023); pyannote; TitaNet.

Reconocer texto y hablantes en una misma salida

La transcripción diarizada puede ser modular o conjunta.



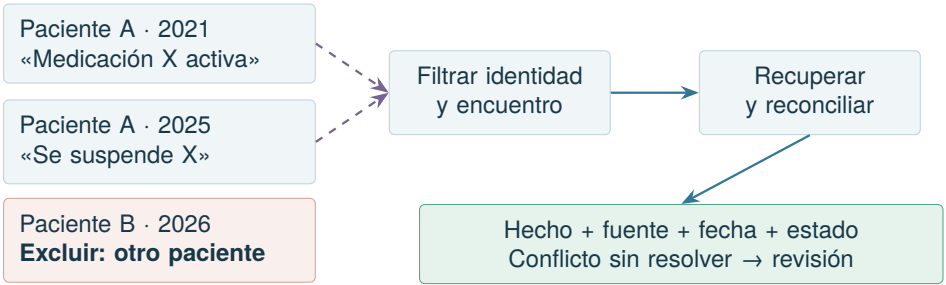
cpWER: texto con atribución de hablante · tcpWER: añade restricciones temporales
Un buen resultado general necesita validación clínica en español.

* MOSS-Transcribe-Diarize. La serialización concreta depende del modelo; SOT es otra línea de reconocimiento multihablante.

Fuentes: MOSS-Transcribe-Diarize (2026); Kanda et al., SOT (2020); MeetEval. Salida ilustrativa.

Recuperar contexto exige paciente, fecha y procedencia

Más texto disponible implica más decisiones sobre relevancia y vigencia.

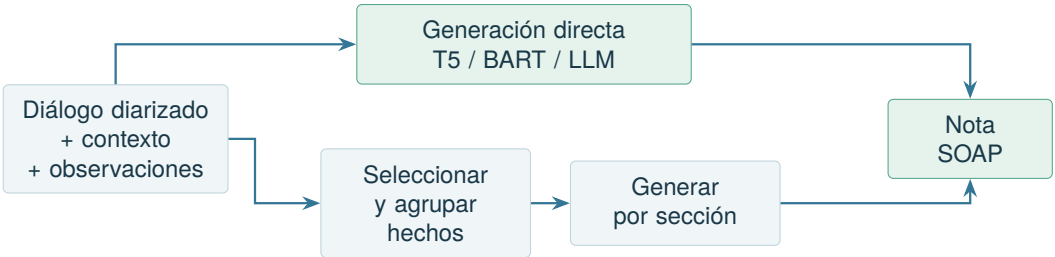


Evaluar recuperación (Recall@k / nDCG) y uso del contexto: paciente correcto, fecha, soporte y contradicciones.

Fuentes: MedAlign; DPR; RAG; FHIR Provenance. Ejemplo y diseño propuestos.

Generar una nota también exige seleccionar información

Dos estrategias de modelado para pasar de diálogo y contexto a documentación.



Una representación intermedia facilita inspeccionar qué se selecciona; también puede perder información. Hay que comparar ambas rutas.

Fuentes: T5; BART; CLUSTER2SENT; ACI-Bench.

Entrenar generación: del token al resumen candidato

Caso de estudio: Singh et al. (Nuance, 2023), sobre transcripción → nota.



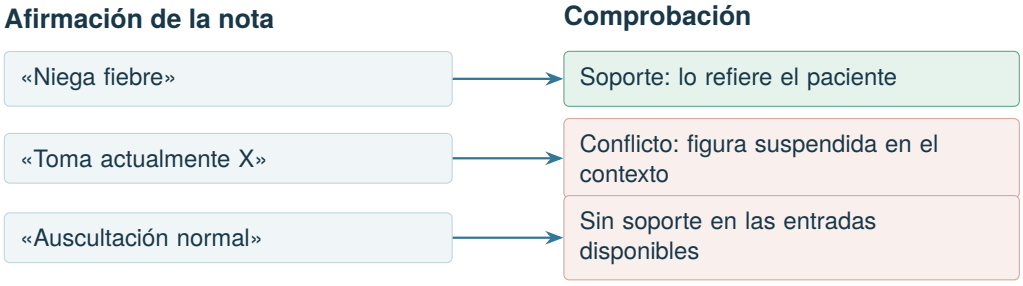
$$\mathcal{L} = \mathcal{L}_{\mathrm{CE}} + \lambda\, \mathcal{L}_{\mathrm{ranking}}$$

Unos 900.000 encuentros privados en inglés; ranking basado en ROUGE-L. Otros trabajos ponderan términos médicos o modelan negación. Ninguna de estas losses garantiza fidelidad clínica.

Fuentes: Singh et al. (2023); BRIO; MedicalSum; Dr. Summarize. Fórmula esquemática.

Verificar hechos y buscar omisiones

Dos direcciones: nota → evidencia y evidencia relevante → nota.

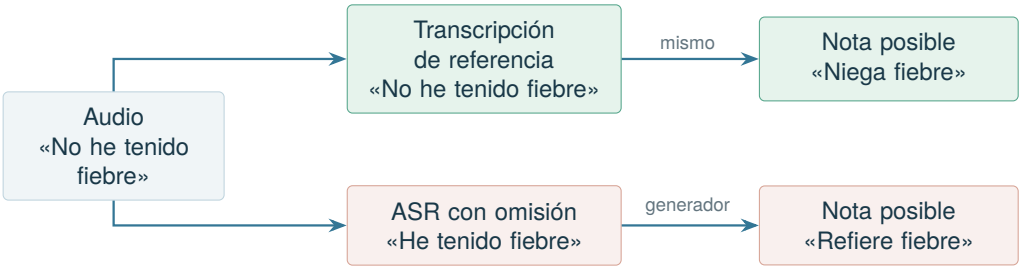


Revisar también qué falta: p. ej., ¿se conservó el seguimiento indicado? Un verificador automático necesita evaluación propia.

Fuentes: VeriFact; FactEHR; Evaluación mediante checklists (2025). Ejemplos ficticios.

Un fallo temprano puede cambiar la nota final

Propagación ilustrativa: una transcripción errónea puede producir una nota muy fluida.



Comparar generación con transcripción de referencia y con ASR ayuda a estimar cuánto error viene de la entrada.

Fuentes: Latif et al., Robust SOAP (2026); Marco de evaluación clínica (2025). Esquema causal propuesto; sin resultados experimentales.

Un experimento común permite localizar los fallos

Propuesta: mantener casos y generador; variar una entrada cada vez.

	Texto	Hablantes	Contexto	Comparación
A	Referencia	Referencia	Validado	Entradas revisadas
B	ASR	Referencia	Validado	A→B: efecto de ASR
C	ASR	Predichos	Validado	B→C: atribución de hablante
D	ASR	Predichos	Recuperado	C→D: recuperación/contexto

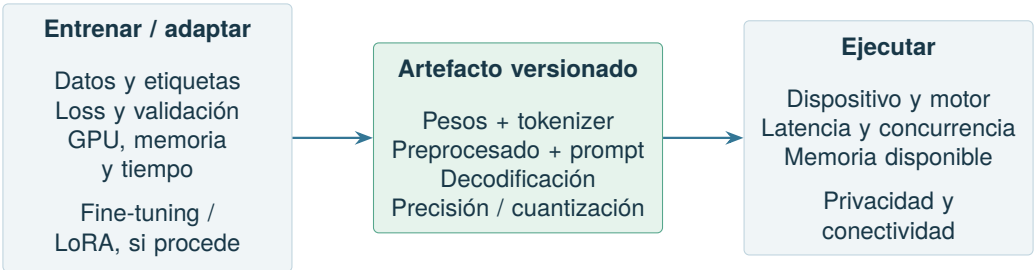
Datos separados
Entrenamiento / ajuste / test por encuentro y paciente; controlar hablantes repetidos.

Evaluación compartida
Revisión clínica ciega cuando sea viable: errores, edición y tiempo.

Fuentes: Diseño propuesto, inspirado en Robust SOAP; Moramarco et al.; evaluación por etapas. Requiere referencias alineadas; las diferencias dependen del resto de la configuración.

Entrenamiento y ejecución tienen restricciones distintas

Adaptar un modelo y servirlo en consulta son dos procesos diferentes.

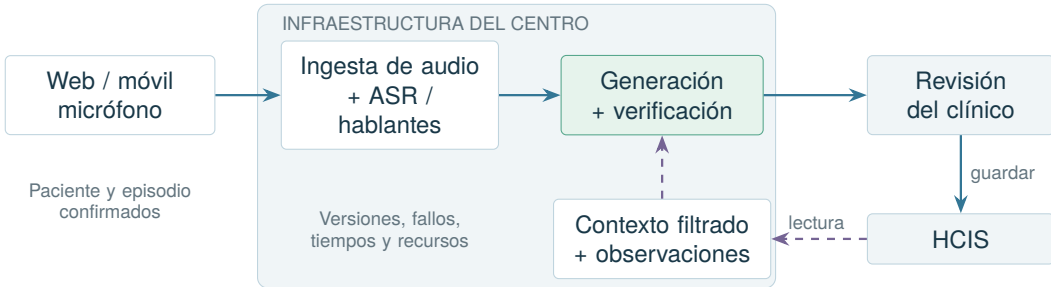


Primero medir un modelo disponible; adaptar después para un error o una necesidad concreta.

Fuentes: LoRA; faster-whisper; whisper.cpp; vLLM. Diseño propuesto.

Arquitectura propuesta para un prototipo local

Procesamiento en infraestructura del centro; interfaces y conectores por concretar.

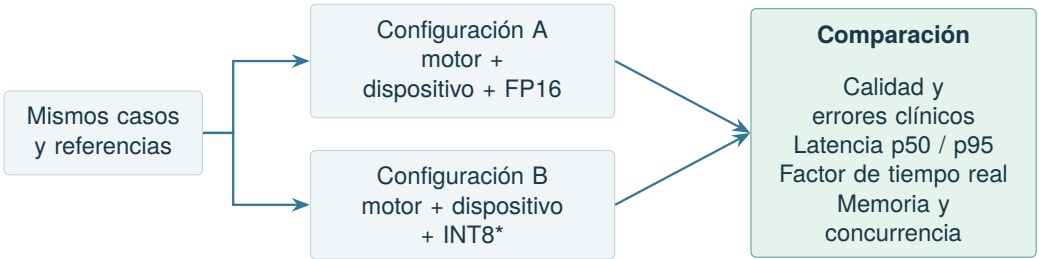


Captura: permisos, canales y cortes. Transporte: p. ej., WebRTC o WebSocket seguro según el flujo. Definir qué se conserva y durante cuánto tiempo.

Fuentes: getUserMedia; WebRTC; FHIR DocumentReference. Esquema propuesto; no presupone un conector HCIS disponible.

Medir con la configuración que se desplegará

El modelo evaluado incluye su preprocesado, motor, precisión y hardware.

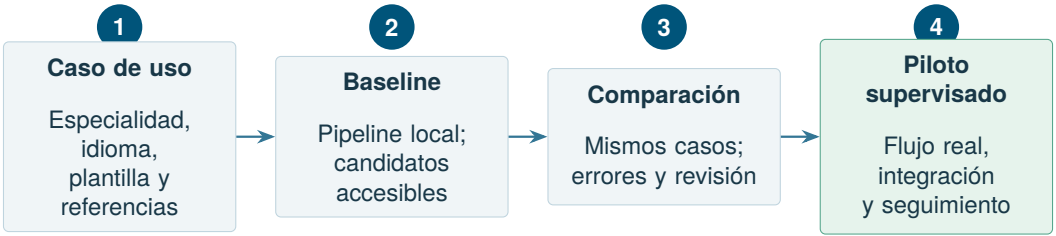


* Si está soportado. Cambiar precisión o motor puede cambiar la salida: medir, no asumir equivalencia.

Fuentes: faster-whisper; whisper.cpp. Protocolo propuesto; sin mediciones de rendimiento todavía.

Siguientes pasos: un baseline y evidencia comparable

Propuesta de trabajo, antes de decidir qué adaptar o qué proveedor elegir.



Para comparar proveedores: acceso viable tras revisar seguridad, protección de datos, coste e integración HCIS.

El conjunto de evaluación debe servir tanto al prototipo local como a los candidatos comerciales.

Fuentes: Plan propuesto. Criterios técnicos apoyados en evaluación clínica por etapas; evaluación humana de notas.

El primer entregable es una evaluación reproducible

Un baseline en español con casos revisados y errores que podamos explicar.

Entradas trazables

Audio + hablantes
Contexto + observaciones
Referencia clínica

Errores localizables

Palabras y atribución
Hechos, omisiones y soporte
Carga de revisión

Ejecución reproducible

Modelos y prompts
Motor y hardware
Mismas condiciones

La siguiente decisión se toma sobre fallos observados.

Después: decidir qué mejorar, qué comprar y qué merece probarse en consulta.

A · Datasets: referencias adicionales y volumen

Una selección para profundizar; horas, encuentros y pares miden cosas distintas.

Recurso	Volumen	Uso y límite principal
Common Voice 17 · ES	2.220 h totales; 562 h validadas	ASR general en español; lectura, no consulta.
DIHARD III	Dev: 34,15 h / 254 grabaciones; eval: 33,01 h / 259	Diarización en dominios diversos; fijar protocolo.
VoxConverse	Más de 50 h, según página del corpus	Vídeo multihablante; distinto del entorno clínico.
MedAlign	983 instrucciones; 303 respuestas de referencia; 276 EHR	Uso de historia clínica; no corpus audio→SOAP.
MedNLI	14.049 pares: 11.232 / 1.395 / 1.422	Inferencia clínica textual; dominio hospitalario.
MIMIC-IV-Note 2.2	331.794 altas; 2.321.355 informes radiológicos	Documentación clínica; sin audio emparejado.
FactEHR	2.168 notas; 987.266 pares de inferencia; 1.036 ejemplos humanos	Verificación: distinguir datos generados de validación humana.

Fuentes: Common Voice ES; DIHARD III; VoxConverse; MedAlign; MedNLI; MIMIC-IV-Note; FactEHR. Detalle de versiones y acceso: README.md.

B · Tarea, métrica y loss: mapa de consulta

Tarea	Evaluación	Objetivos de entrenamiento habituales
ASR	WER / CER; entidades y errores clínicos	CTC; CE/NLL; transducer. Preentrenamiento autosupervisado según modelo.
Diarización	DER / JER, con collar y solapamiento definidos	BCE + PIT (EEND); CE powerset; pérdidas de embeddings, p. ej. margen angular.
Transcripción diarizada	cpWER / tcpWER; WER y DER complementarios	CE sobre secuencias serializadas o pérdidas separadas en sistemas modulares.
Recuperación	Recall@k / nDCG; paciente, fecha y relevancia	Contrastiva para retrievers densos; CE/ranking en rerankers.
Generación de nota	ROUGE/BERTScore + hechos, omisiones, contradicciones y revisión clínica	CE/NLL; ranking de candidatos (BRIO); ponderación clínica según trabajo.
Verificación	Precision/recall/F1; calibración; errores por tipo	CE para clasificación de inferencia; CE de generación, si se adapta un LLM.
Sistema completo	Calidad de nota + revisión + tiempo + incidencias	Depende de la arquitectura. No existe una única loss estándar audio→nota.

Fuentes: Jurafsky y Martin, cap. 16; EEND; BRIO; DPR; MedNLI. Catálogo ampliado: README.md.

C · Lecturas para sostener la presentación

Para entender…	Empezaría por…
La nota y su función	The anatomy of clinical documentation; Safe use of the EHR. Estructura, contexto y revisión.
Audio y ASR	Jurafsky y Martin, cap. 15 y cap. 16; Whisper. De la señal al texto.
Hablantes	EEND; powerset; MOSS. Salidas, solapamiento y enfoques conjuntos.
Diálogo → nota	Singh et al.; ACI-Bench; CLUSTER2SENT. Datos, arquitectura y entrenamiento.
Evaluación y contexto	Moramarco et al.; Robust SOAP; MedAlign; VeriFact. Localizar fallos y comprobar soporte.

Material de apoyo: README.md · common_challenges.md · clinical_note_context.md

Guion con tiempos y transiciones: guion-presentacion.md