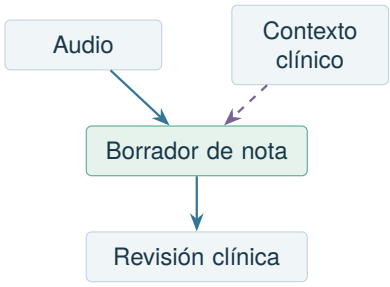
Construir un escriba digital médico

De la consulta a una nota clínica



Borrador técnico · 30 minutos
Tareas, evaluación, modelos y ejecución local

Objetivo y alcance

Documentar el encuentro y facilitar la revisión del profesional.



¿Cómo producir una nota correcta y reducir el trabajo de cerrarla?

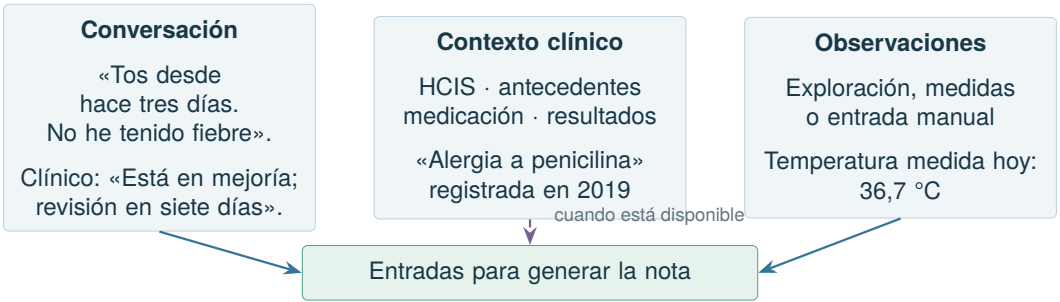
1. Consulta y nota
2. Evaluación y datos
3. Audio y hablantes
4. Diálogo, contexto y nota
5. Adaptación y despliegue
6. Plan de trabajo

Los escribas humanos documentan bajo supervisión clínica. Algunos productos amplían esta función a informes, codificación o ayuda a decisiones; aquí estudiamos la nota.

Fuentes: Ash et al., Safe use of the EHR; Coiera et al., Taking note; Tandem: funciones declaradas del producto.

Información del encuentro

Ejemplo ficticio que seguiremos hasta la nota.



Conservar quién aporta cada dato, cuándo y de qué fuente procede.

Fuentes: The anatomy of clinical documentation (2021); MedAlign (2023). Ejemplo propio.

La nota SOAP

Una forma habitual de estructurar la nota; las plantillas cambian entre servicios.

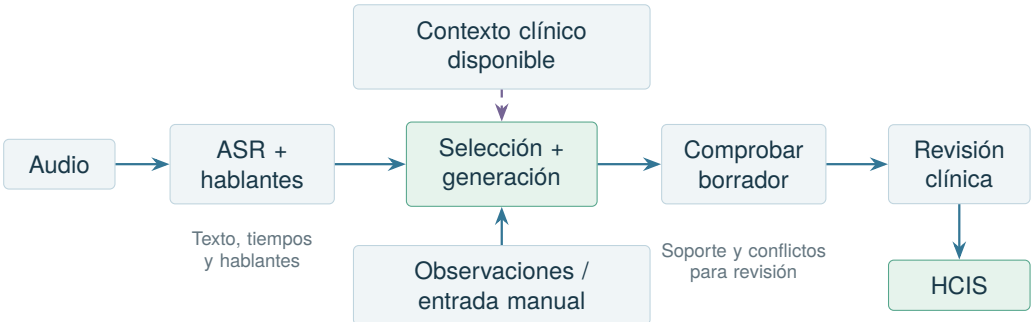
S	**Subjetivo**	Tos de tres días; niega fiebre.	Relato del paciente
O	**Objetivo**	Temperatura: 36,7 °C.	Medición de hoy
A	**Valoración**	En mejoría, según valoración clínica.	Juicio expresado por el clínico
P	**Plan**	Revisión en siete días, indicada por el clínico.	Decisión expresada en consulta

Contexto adicional: alergia registrada en 2019, pendiente de confirmar. Puede aparecer en una sección específica de antecedentes/alergias.

Fuentes: SOAP Notes, StatPearls; The anatomy of clinical documentation. Ejemplo ficticio; A y P documentan al clínico.

Pipeline del escriba

Entradas y salidas que podamos inspeccionar.



La selección de hechos puede ocurrir dentro del generador o quedar explícita. Comprobar el borrador aporta señales de revisión; su fiabilidad también se evalúa.

Fuentes: Diseño de trabajo, no implementación completa. Evaluación clínica por etapas; Singh et al.; VeriFact. HCIS: sistema de información clínica.

Evaluación

El éxito se mide en la nota y en el trabajo necesario para cerrarla.

Audio y hablantes	¿Se reconocieron las palabras y quién las dijo? WER, errores clínicos y atribución.
Contenido de la nota	¿Qué falta, qué sobra y qué se contradice? Hechos, negación, sujeto, fecha y soporte.
Uso clínico	¿Cuánto esfuerzo exige revisar y corregir? Tiempo, ediciones e incidencias del flujo.

Necesitamos referencias anotadas para medir errores y revisión clínica para valorar su importancia.

Fuentes: Moramarco et al., evaluación y post-edición; Marco clínico de evaluación (2025).

Datos de evaluación

Primero referencias estándar; después datos que se acerquen al uso previsto.

1 · Referencias generales

LibriSpeech
960 h de entrenamiento ASR; inglés leído.

AMI
Unas 100 h de reuniones; audio y hablantes.

FLEURS
102 idiomas, unas 12 h/idioma; incluye español.

2 · Consulta clínica en inglés

PriMock57
57 consultas simuladas; 8 h 38 min; audio, turnos y notas.

ACI-Bench
207 encuentros simulados; transcripciones y notas; sin audio público.

MTS-Dialog
1.701 pares breves diálogo–sección.

3 · Aproximación al español clínico

TEME-v1
90 diálogos, 2.330 turnos, 3,96 h de audio TTS; dos voces.

Útil para explorar ASR; sin tiempos de referencia para evaluar DER directamente.

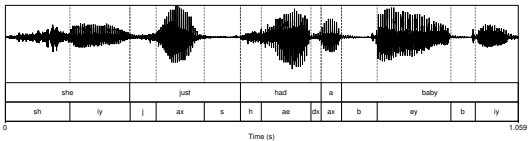
Conjunto local propuesto
Consultas y notas revisadas del escenario de uso.

Fuentes: LibriSpeech; AMI; FLEURS; PriMock57; ACI; MTS; TEME. Horas TEME: suma local de los 90 MP3.

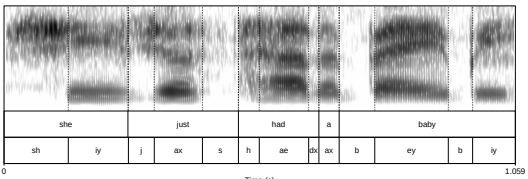
Señal y representación acústica

«She just had a baby»: la misma frase en onda y espectrograma.

Onda y alineamiento



Espectrograma



Captura
Canales, muestreo, ruido y compresión.

Ventanas
Analizar cómo cambia el espectro con el tiempo.

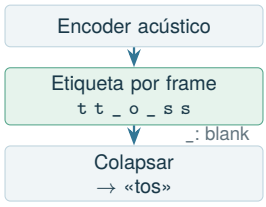
Entrada del modelo
Log-Mel, o representación aprendida de la onda.

Fuentes: Jurafsky y Martin, cap. 15, figs. 15.15 y 15.22, borrador 19/08/2026. Recortes del libro; habla de Switchboard en inglés, no consulta clínica. Whisper: entrada log-Mel.

Modelos de ASR

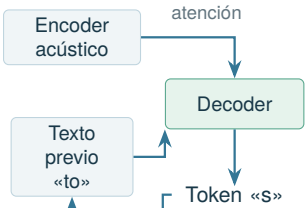
Cómo pasar de estados acústicos a una secuencia de texto.

CTC



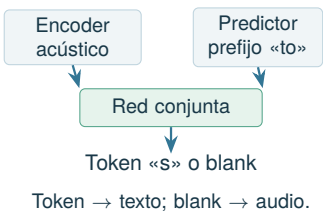
Greedy sencillo.
Etiquetas independientes dado el audio.

Encoder–decoder



Whisper atiende al audio del segmento.
Decoding token a token.

RNN-T



Token → texto; blank → audio.

Incremental con encoder causal.
Decoding más complejo.

Elegir un modelo concreto exige medir español clínico, velocidad y memoria. La familia de arquitectura por sí sola no determina su calidad.

Fuentes: Esquema propio: Jurafsky y Martin, cap. 16; Prabhavalkar et al., survey; Whisper. Ejemplo de caracteres simplificado.

WER y errores clínicos

Referencia: «el paciente no refiere fiebre desde ayer» · 7 palabras.

A · Sustitución

este paciente no refiere fiebre desde ayer

B · Omisión de una negación

el paciente **[—]** refiere fiebre desde ayer

$$\mathrm{WER} = \frac{S+D+I}{N}$$

Ambos: $1/7 = 0{,}143$
14,3 %

S: sustituciones · D: eliminaciones · I: inserciones · N: palabras de referencia.

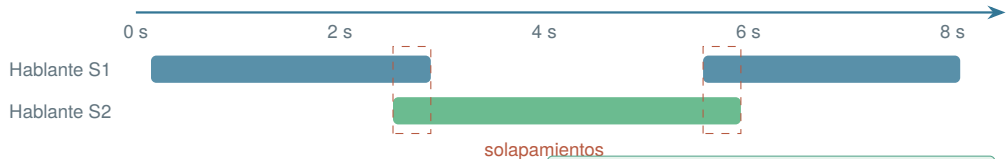
Añadir revisión de entidades, negaciones, dosis, fechas y su impacto clínico. El WER sigue siendo útil para diagnosticar ASR.

Fuentes: Definición y cálculo: JiWER; evaluación médica: Medical ASR benchmark (2024); TEME. Ejemplo propio.

Diarización: tiempo, hablante y rol

Un identificador de hablante no identifica por sí mismo a una persona ni su rol clínico.

1. Quién habla y cuándo



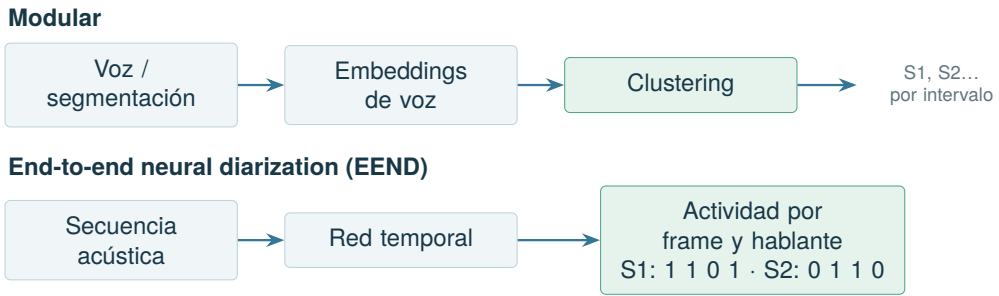
2. Qué dice
S1: «¿Ha tenido fiebre?»

3. Qué rol tiene
S1: clínico · S2: paciente, tras validarlo

Fuentes: DIHARD III; dscore. Línea temporal ilustrativa; el rol es una etiqueta adicional.

Modelos de diarización

Dos familias; ruido, turnos cortos y solapamiento ponen a prueba ambas.

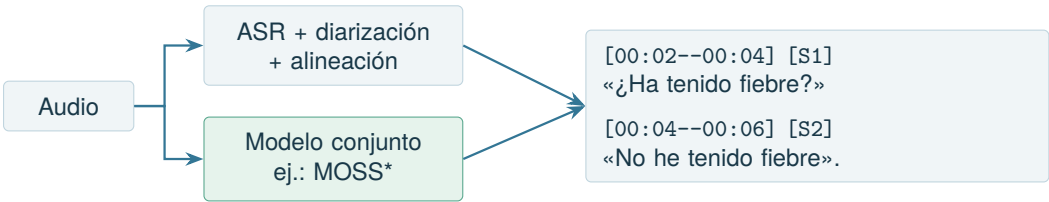


Modular: etapas sustituibles; el agrupamiento necesita suficiente evidencia de voz. **EEND:** modela actividad simultánea; la generalización al número de hablantes y sesiones largas depende del modelo. **Medir:** DER/JER, con tolerancia temporal y solapamiento definidos.

Fuentes: Fujita et al., EEND (2019); Plaquet y Bredin, powerset (2023); pyannote; TitaNet.

Transcripción con hablantes

La transcripción diarizada puede ser modular o conjunta.



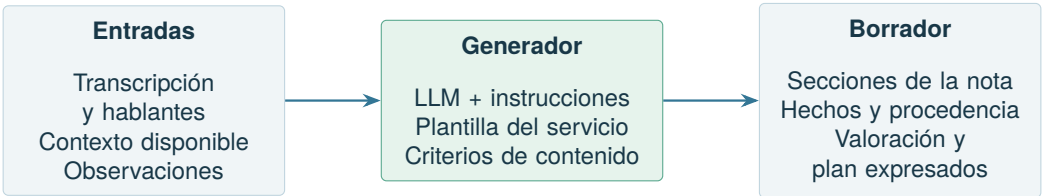
cpWER: texto con atribución de hablante · tcpWER: añade restricciones temporales
Comparar reconocimiento, atribución y coste en consultas clínicas.

* MOSS-Transcribe-Diarize. Salida ilustrativa; las etiquetas no establecen por sí solas los roles.

Fuentes: MOSS-Transcribe-Diarize (2026); MeetEval. Salida ilustrativa.

Generación de notas

Primero definir qué documentar y cómo debe verse la salida.



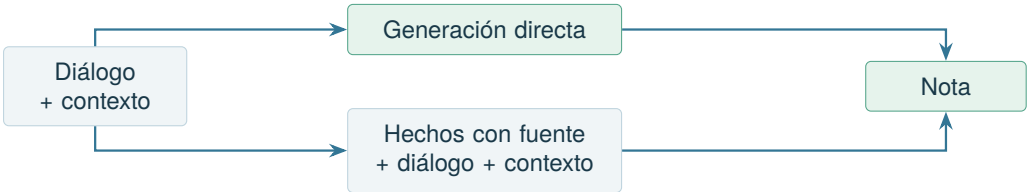
El equipo clínico define contenido, estilo y errores relevantes; esas decisiones se convierten en instrucciones y criterios de evaluación.

Comparar plantillas y prompts sobre los mismos encuentros antes de decidir si hace falta adaptar pesos.

Fuentes: ACI-Bench; Moramarco et al.. Baseline propuesto para el proyecto.

Selección de hechos

La relevancia puede decidirse al redactar o representarse antes de la nota.



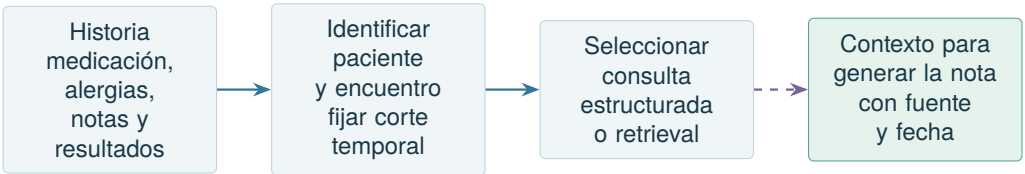
«Mi madre toma X» → **sujeto: madre**, no paciente
Hecho · sujeto · negación · momento · fragmento de soporte

ASCRIBE: hechos + soporte + relevancia. KOSMOS: entidades, atributos y relaciones. Son estrategias para comparar; la extracción puede introducir omisiones.

Fuentes: ASCRIBE (2026, preprint; tailandés); KOSMOS (2026); antecedente: Chain-of-Clinical-Facts, Nuance (2023). Sin validación local en español.

Contexto de la historia clínica

Seleccionar registros externos es una tarea distinta de extraer hechos del diálogo.

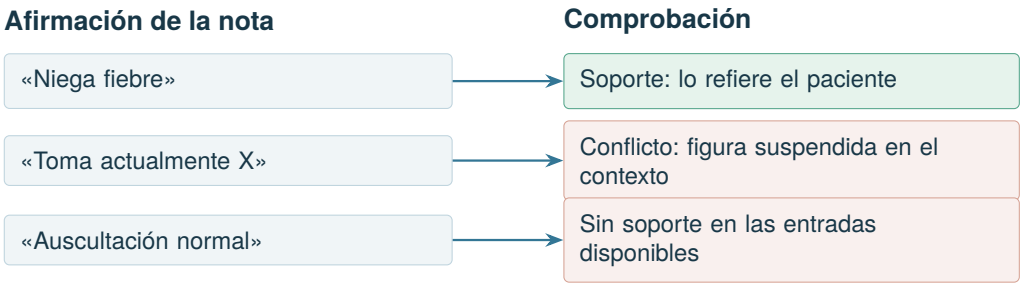


Conservar antecedentes relevantes de otros episodios. Contexto corto: selección estructurada; historia extensa: comparar retrieval. Medir relevancia, vigencia y efecto en la nota.

Fuentes: Diseño propuesto. RAG; FHIR Provenance. MedAlign estudia instrucciones sobre EHR, no valida este conector ni recuperador.

Comprobaciones de la nota

¿Qué respalda cada afirmación y qué información relevante falta?

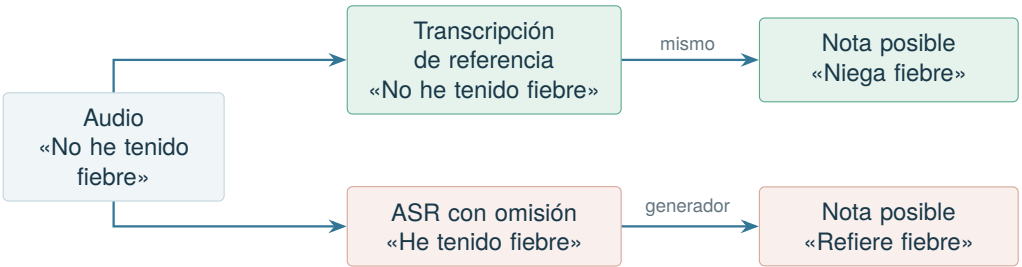


Se puede buscar soporte sin nota gold por caso. Medir si el verificador acierta y qué omite exige una muestra anotada.

Fuentes: VeriFact; FactEHR; Evaluación mediante checklists (2025). Ejemplos ficticios.

Propagación de errores

Propagación ilustrativa: una transcripción errónea puede producir una nota muy fluida.



Si generador y verificador leen el mismo ASR erróneo, pueden compartir el fallo. Conservar el vínculo con el audio.

Fuentes: Latif et al., Robust SOAP (2026); Marco de evaluación clínica (2025). Esquema causal propuesto; sin resultados experimentales.

Experimento por etapas

Casos con referencias: mantener generador y plantilla; variar una entrada.

	Texto	Hablantes	Contexto	Comparación
A	Referencia	Referencia	Validado	Entradas revisadas
B	ASR	Referencia	Validado	A→B: sensibilidad a ASR
C	ASR	Predichos	Validado	B→C: sensibilidad a atribución
D	ASR	Predichos	Recuperado	C→D: sensibilidad al contexto

Datos separados
Separar ajuste y test por paciente/encuentro; las variantes sintéticas del mismo caso van juntas.

Evaluación compartida
Revisión clínica con rúbrica: errores y edición. Alinear palabras ASR con hablantes de referencia.

Fuentes: Diseño propuesto, inspirado en Robust SOAP; Moramarco et al.; evaluación por etapas. Requiere referencias alineadas; las diferencias dependen del resto de la configuración.

Qué adaptar y con qué datos

La intervención debe responder a un fallo observado.

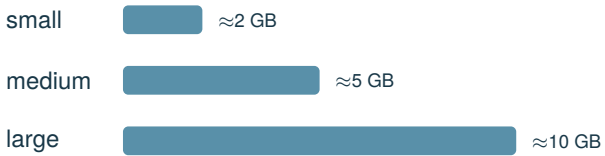
Problema medido	Intervención candidata	Datos y comprobación
Terminología médica y acento en ASR	Configuración, vocabulario	Audio + texto revisado test clínico español
Estilo, selección de hechos o uso del contexto	Plantilla, prompt, extracción o adaptación del generador	Diálogo/contexto + nota criterios de clínicos
Latencia o memoria insuficientes	Motor, tamaño de modelo o cuantización	Mismos casos y hardware calidad + tiempo + memoria

Fuentes: Plan propuesto. Whisper; LoRA; ASCRIBE: adaptación de generación; faster-whisper. Losses de entrenamiento en anexo B.

Recursos para ejecución local

Órdenes de magnitud para elegir qué medir; no son un presupuesto del sistema.

Whisper: VRAM aproximada



LLM de 7B: solo pesos

FP16: ≈14 GB
4 bits: ≈3,5 GB

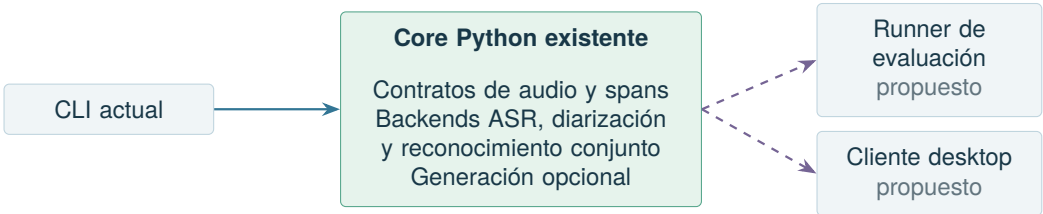
Añadir KV cache, buffers, ASR/diarización y concurrencia.

El motor y la precisión cambian consumo y velocidad. Cuantizar exige volver a medir calidad.

Fuentes: Whisper README: estimaciones de su implementación. Cálculo nominal de pesos 7B: parámetros × bits / 8, GB decimales; no medición. whisper.cpp.

Scribnic: núcleo y clientes

Base del proyecto actual y ampliaciones propuestas.

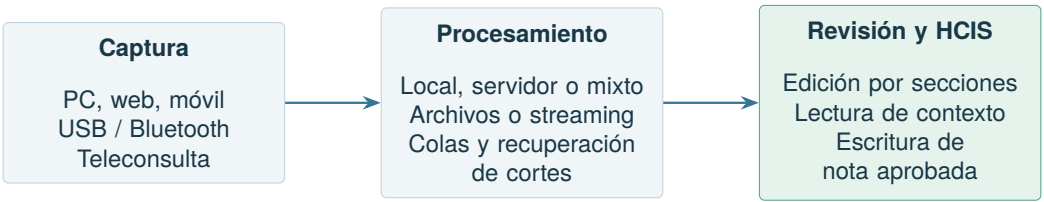


Pendiente: contrato de contexto clínico, referencias/métricas y cliente de revisión.
Los adaptadores y tests de contratos no demuestran calidad clínica.

Fuentes: Inspección del código local (10/10/2026): `mypipe/src/scribnic/core.py`, `models.py`, `factory.py` y `README.md`. Estado del proyecto; no resultados de evaluación.

Captura e integración

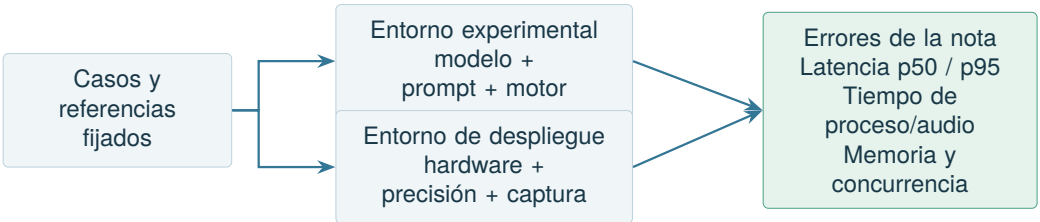
La plataforma determina cómo llega la información y cómo se revisa.



Fuentes: Captura web; WebRTC; FHIR DocumentReference; Tandem: edición por voz y documentos. Opciones de diseño, no conectores implementados.

Evaluación del sistema desplegado

Comprobar calidad y funcionamiento en la configuración de uso.



Después de cada cambio, repetir la evaluación. En piloto: fallos, ediciones y muestra revisada de calidad.

Fuentes: Protocolo propuesto. faster-whisper; whisper.cpp. Sin benchmark de rendimiento local todavía.

Datos del primer experimento

Propuesta acotada para probar el protocolo; no validar todavía el producto.

1 · Componentes

TEME: ASR español TTS
PriMock57: audio, turnos y notas en inglés

Referencias públicas

2 · Contexto y nota

10 casos con contexto
5 consultas PriMock adaptadas al español

Referencias revisadas

3 · Protocolo clínico

Hechos y fuentes esperados
Errores, omisiones y edición
Acuerdo entre revisores

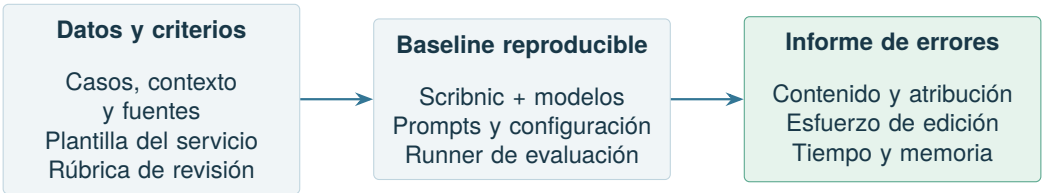
Test separado del ajuste

Números propuestos para una prueba de viabilidad. Datos sintéticos y traducciones no sustituyen una evaluación posterior con consultas reales.

Fuentes: Plan del proyecto. TEME-v1; PriMock57; Marco clínico de evaluación. Ampliaciones: bag-of-ideas.md y anexo D.

Propuesta de trabajo

Construir un baseline local y averiguar dónde necesita mejorar.



La evaluación decidirá qué adaptar y qué merece pasar a un piloto supervisado.

El hospital aporta acceso a criterios clínicos y revisores. El objetivo abierto y local necesita primero evidencia de calidad y viabilidad.

A · Datasets: referencias adicionales y volumen

Una selección para profundizar; horas, encuentros y pares miden cosas distintas.

Recurso	Volumen	Uso y límite principal
Common Voice 17 · ES	2.220 h totales; 562 h validadas	ASR general en español; lectura, no consulta.
DIHARD III	Dev: 34,15 h / 254 grabaciones; eval: 33,01 h / 259	Diarización en dominios diversos; fijar protocolo.
VoxConverse	Más de 50 h, según página del corpus	Vídeo multihablante; distinto del entorno clínico.
MedAlign	983 instrucciones; 303 respuestas de referencia; 276 EHR	Uso de historia clínica; no corpus audio→SOAP.
MedNLI	14.049 pares: 11.232 / 1.395 / 1.422	Inferencia clínica textual; dominio hospitalario.
MIMIC-IV-Note 2.2	331.794 altas; 2.321.355 informes radiológicos	Documentación clínica; sin audio emparejado.
FactEHR	2.168 notas; 987.266 pares de inferencia; 1.036 ejemplos humanos	Verificación: distinguir datos generados de validación humana.

Fuentes: Common Voice ES; DIHARD III; VoxConverse; MedAlign; MedNLI; MIMIC-IV-Note; FactEHR. Detalle de versiones y acceso: README.md.

B · Tarea, métrica y loss: mapa de consulta

Tarea	Evaluación	Objetivos de entrenamiento habituales
ASR	WER / CER; entidades y errores clínicos	CTC; CE/NLL; transducer. Preentrenamiento autosupervisado según modelo.
Diarización	DER / JER, con collar y solapamiento definidos	BCE + PIT (EEND); CE powerset; pérdidas de embeddings, p. ej. margen angular.
Transcripción diarizada	cpWER / tcpWER; WER y DER complementarios	CE sobre secuencias serializadas o pérdidas separadas en sistemas modulares.
Recuperación	Recall@k / nDCG; paciente, fecha y relevancia	Contrastiva para retrievers densos; CE/ranking en rerankers.
Generación de nota	ROUGE/BERTScore + hechos, omisiones, contradicciones y revisión clínica	CE/NLL; ranking de candidatos (BRIO); ponderación clínica según trabajo.
Verificación	Precision/recall/F1; calibración; errores por tipo	CE para clasificación de inferencia; CE de generación, si se adapta un LLM.
Sistema completo	Calidad de nota + revisión + tiempo + incidencias	Depende de la arquitectura. No existe una única loss estándar audio→nota.

Fuentes: Jurafsky y Martin, cap. 16; EEND; BRIO; DPR; MedNLI. Catálogo ampliado: README.md.

C · Hechos intermedios: tres implementaciones

Representar hechos del encuentro es distinto de recuperar historia externa.

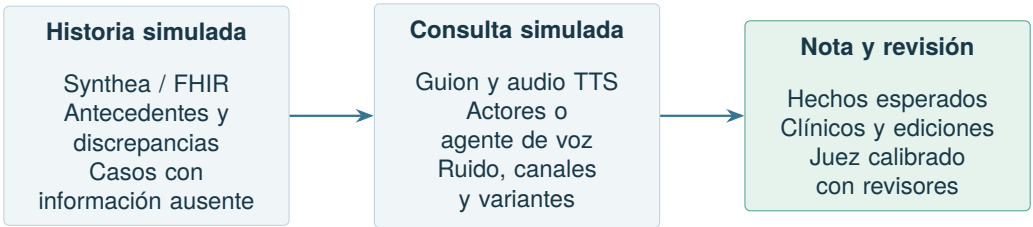
Trabajo	Qué hace	Qué limita la conclusión
Nuance (2023)	Hechos extraídos de notas de referencia como prefijo de entrenamiento; en inferencia, genera hechos y después nota desde la transcripción.	≈900.000 encuentros privados en inglés. No incorpora HCIS por retrieval.
ASCRIBE (2026)	Hechos atómicos + soporte + relevancia antes de SOAP; prompting y adaptación con rewards.	Tailandés; muestra clínica pequeña; jueces LLM y validación limitada con un médico. Preprint.
KOSMOS (2026)	Entidades, atributos y relaciones con procedencia; compara transcripción + nodos/grafo.	Mejoras modestas; extracción sin evaluación independiente; no demuestra menor tiempo de revisión.

Experimento propuesto: directo frente a hechos con fuente + diálogo, manteniendo casos, contexto, plantilla y generador.

Fuentes: Singh et al. §3.1.2; ASCRIBE §3.1 y prompt A.3; KOSMOS §2. Ficha: comprension-clinica.md.

D · Ideas para ampliar los datos

Experimentos posibles después del primer conjunto de viabilidad.



MIRA aporta un entorno EHR/paciente para decisiones clínicas; no un corpus audio→nota. Adaptar PriMock al español y recoger consultas reales son otras vías.

Fuentes: Synthea; MIRA (2026; acceso MIMIC controlado); PriMock57. Propuestas y límites en bag-of-ideas.md.

E · Lecturas para preparar la discusión

Para entender…	Empezaría por…
La consulta y la nota	The anatomy of clinical documentation; Safe use of the EHR. Contenido, fuentes y revisión.
Audio y ASR	Jurafsky, cap. 15 y cap. 16; Whisper. Señal, características y reconocimiento.
Hablantes	EEND; powerset; MeetEval. Actividad, atribución y protocolo.
Selección y contexto	ASCRIBE; KOSMOS; Nuance. Leer método y limitaciones; ficha comprension-clinica.md.
Evaluación de notas	Moramarco et al.; Robust SOAP; VeriFact. Revisión, omisión y soporte.

Guion con hilo, tiempos y transiciones: guion-presentacion.md

Preguntas de defensa y ejercicios: preguntas-defensa.md · Datos y volúmenes: README.md